




Giffaux Thomas
Data Analyste
mai 2025





SOMMAIRE

Analyses exploratoires des données

- ERP
- Web
- Liaison
- Améliorations

Analyses des données

- Analyses univariées du prix
- Analyses complémentaires

Analyses exploratoires des données




ERP

référence produit, prix
et l'état du stock



Web

sku, quantités vendues,
description des
produits, etc



Liaison

permet de lier les
référence entre la base
de données ERP et Web





ERP

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 6 columns):
#   Column                Non-Null Count  Dtype
---  -
0   product_id            825 non-null   int64
1   onsale_web            825 non-null   int64
2   price                 825 non-null   float64
3   stock_quantity        825 non-null   int64
4   stock_status          825 non-null   object
5   purchase_price        825 non-null   float64
dtypes: float64(2), int64(3), object(1)
memory usage: 38.8+ KB
```

Les données viennent de l'extraction du système de l'entreprise qui n'est pas relié avec le site de vente en ligne. On peut retrouver des informations importantes comme :

- savoir si le produit est en ligne
- le stock
- le prix d'achat
- le prix de vente





Stock / Statut / Prix

Stock

Max

145 (4337)

Min

-1 (5700)

-10 (4973)

Tous les stocks sont renseignés mais deux références ont une quantité de stock négatif. Le stock peut-être mal renseigné dans la base de donnée.

Statut

instock

> 0

Après vérification, deux référence ont une erreur dans leur statut :

outofstock

=< 0

- 4039 ; stock de 3 mais outofstock
- 4885 ; stock de 0 mais instock

Prix

id

Online

Stock

Prix d'achat

Prix de vente

4233

non

0

10,33

-20,00

5017

non

0

4,34

-8,00

6594

non

19

4,61

-9,10

Tous les prix sont bien renseignés dans la base de données. Trois références ont un prix de vente négatif





Web

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1513 entries, 0 to 1512
Data columns (total 29 columns):
#   Column                Non-Null Count  Dtype
---  -
0   sku                   1428 non-null   object
1   virtual              1513 non-null   int64
2   downloadable         1513 non-null   int64
3   rating_count         1513 non-null   int64
4   average_rating       1430 non-null   float64
5   total_sales          1430 non-null   float64
6   tax_status           716 non-null    object
7   tax_class            0 non-null      float64
8   post_author          1430 non-null   float64
9   post_date            1430 non-null   datetime64[ns]
10  post_date_gmt        1430 non-null   datetime64[ns]
11  post_content         0 non-null      float64
12  product_type         1429 non-null   object
13  post_title           1430 non-null   object
14  post_excerpt        716 non-null    object
15  post_status         1430 non-null   object
16  comment_status      1430 non-null   object
17  ping_status         1430 non-null   object
18  post_password       0 non-null      float64
19  post_name           1430 non-null   object
20  post_modified       1430 non-null   datetime64[ns]
21  post_modified_gmt   1430 non-null   datetime64[ns]
22  post_content_filtered 0 non-null      float64
23  post_parent        1430 non-null   float64
24  guid               1430 non-null   object
25  menu_order         1430 non-null   float64
26  post_type          1430 non-null   object
27  post_mime_type     714 non-null    object
28  comment_count      1430 non-null   float64
dtypes: datetime64[ns](4), float64(10), int64(3), object(12)
memory usage: 342.9+ KB
```

Les données viennent de l'export de la boutique en ligne. On a beaucoup d'information mais les principales sont :

- le nom du produit
- sa description
- son type
- le nombre de vente sur octobre





Doublons / Sku

Doublons

82

lignes sont des doublons
dans cet export

Après vérification ce sont des lignes dupliquées qui ne contiennent dans leur cellules que des NaN, des zéro ou aucune valeur. On peut donc les supprimer.

Sku

Le Sku est un identifiant produit souvent utilisé dans les boutiques en ligne. Sur les 714 références uniques, après vérification certaines valeurs ne semblent pas respecter les règles de codification.

NaN

Les lignes contiennent des valeurs.

bon-cadeau-25-euros

Un vrai bon de cadeau qui devrait disparaître après utilisation

13127-1


Les valeurs des lignes semble correct.



Liaison

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 825 entries, 0 to 824  
Data columns (total 2 columns):  
#   Column      Non-Null Count  Dtype  
---  ---  
0   id_web      734 non-null    object  
1   product_id  825 non-null    int64  
dtypes: int64(1), object(1)  
memory usage: 13.0+ KB
```

Cette table de liaison permet de lier les références entre la base de données web et l'extraction de l'ERP de l'entreprise. Les numéros des références ne correspondent pas entre les deux outils.



Les nombres de références uniques varient entre le fichier.



id_web / product_id

825

Nombre de référence unique dans la table liaison, autant que sur le fichier ERP. Après vérification ce sont les mêmes références.

91

Références ne sont pas renseignées sur le fichier liaison. Ce sont peut-être des références qui ne sont pas vendues en ligne.

88

Sont bien des références qui ne sont pas vendues en ligne.

3

Références ne sont pas renseignées alors qu'elles sont vendues en ligne : 4594 ; 5070 ; 5075

Le fichier liaison ne doit pas être à jour.



Amélioration




Après l'analyse exploratoire des données, on peut observer qu'il y a quelques erreurs non négligeables :

- Quantité
- Valeur
- Stock
- Status
- Références
- Doublon

Voyons dans cette partie, quelques axes d'amélioration pour améliorer les données des systèmes utilisés.

Puis dans un second temps voir les améliorations avec la conformité RGPD.



Fichiers

ERP

Quantité : vérification des stocks régulière. Voir le fonctionnement du système pour le statut de stock et leur quantité.

Prix : limiter les prix pour éviter les saisies négatifs. Message de validation du système si la marge est négative.

Web

Doublons : vérification des doublons et de la cause de la duplication des ces lignes.

Bon cadeau : les lignes devraient être supprimé après utilisation/vente.

Sku : mise à jour des références selon les règles de codification.

Liaison

id_web : mise à jour avec le sku de l'extraction du site en ligne.

Vérification des lignes sans correspondance. remettre à jour tout le fichier liaison.



RGPD

Entrée en vigueur en 2018, le Règlement Général sur la Protection des Données (RGPD) encadre le traitement des données personnelles sur le territoire européen. il s'articule autour de 3 objectifs :

- Protéger la vie privée ;
- responsabiliser les acteurs traitant des données ;
- réguler par une coopération renforcée.

Référent

Désigner un délégué à la protection des données.

Cartographie

Vision claire des données collectées et de l'endroit des extractions.

Analyse et priorisation

Déterminer les principales actions pour garantir la conformité RGPD.

Gestion des risques

Déterminer l'impact potentiel de ces traitements.

Organisation interne

Réviser et optimiser les procédures internes.

Documenter

Maintenir un registre des traitements des données et centraliser ces documents.

Analyses des données



**Analyses univariées
du prix**



**Analyses
complémentaires**




Analyses univariées du prix




Une analyse univariée consiste à étudier une seule variable, ici le prix. Son but est de comprendre la distribution, les caractéristiques et les éventuelles anomalies. Puis de décrire la tendance générale.

- Minimum : 5,20 € (6129)
- Maximum : 225,00 € (4352)
- Q1 : 14,50 €
- Médiane : 24,30 €
- Q3 : 42,00 €
- Moyenne : 32,19 €
- Écart type : 26,71 €



Visualisation


Histogramme interactif - Prix



La grande majorité des prix est entre 0 et 50 €.

Avec cette forme on distingue bien que la moyenne est tirée vers le haut par des valeurs élevées.

boxplot des prix




La boîte (IQR=entre Q1 et Q3).

Il y a beaucoup de points au dessus de 60 €, ce sont les outliers selon la méthode IQR.

On voit bien les valeurs sous 0 €.



Valeurs extrêmes




Les outliers sont des valeurs anormalement différentes des autres observations d'un ensemble de données. Ils peuvent être des erreurs de saisie ou des cas rares mais réels.

Ici c'est la méthode de l'intervalle Interquartile (IQR) qui a été utilisé.

L'écart de prix des bouteilles de vin peut-être justifié par plusieurs critères :

- si c'est un grand cru classé
- si c'est un millésime ancien ou rare
- l'origine du terroir ou du cépage
- le format de la bouteille



Analyses complémentaires



Les analyses complémentaires permettent d'approfondir la compréhension des données. Cela inclut l'étude des taux de marge, des stocks, des ventes, etc.

Ces analyses permettent d'identifier les produits à forte rentabilité, ceux en surstock ou d'éventuelles anomalies à corriger pour améliorer les performances.

C.A. du mois d'octobre : 143 680,10 €

434 références représentent 80% du C.A.
ce qui correspond à 52,48% des références.



Top CA / Vente

Top 5 CA



Champagne Egly-Ouriet Grand Cru Millésimé
2008
2 475 € (4352)



Coteaux Champenois Egly-Ouriet Ambonnay
Rouge 2016
1 147,80 € (5892)



Champagne Egly-Ouriet Grand Cru Brut Rosé
1 113 € (4353)




Agnès Levet Côte Rôtie Améthyste 2017
824 € (5826)



Domaine des Comtes Lafon Volnay 1er Cru
Santenots du Milieu 2015
805 € (6212)

Top 5 Vente



Château De La Selve IGP Coteaux de l'Ardèche
Maguelonne Rosé 2019
36 (4867)



Mas Laval IGP Pays d'Hérault Les Pampres
Blanc 2018
27 (4203)



I Fabbri Chianti Classico Lamole 2017
24 (4275)



Bernard Baudry Chinon Rouge La Croix
Boissée 2017
22 (4647)



François Baur Pinot Noir Schlittweg 2017
22 (4726)



Marge

Marge

Max
0,48
(4401)

Min
0,23
(5760)



Marge par référence

La référence 4355 est la seule de ces référence qui est en ligne avec du stock.

Il doit avoir une erreur dans son prix de vente.
(126,50 € ?)

Id	Online	Stock	Prix d'achat	Prix de vente
4233	non	0	10,33	-20,00
4355	oui	97	77,48	12,65
4864	non	0	9,99	8,30
5017	non	0	4,34	-8,00
6324	non	18	99,00	92,00
6594	non	19	4,61	-9,10
7196	non	55	31,20	31,00



Stock



Valeur : 298 55,76 €

Quantité : 17 811

Produit avec le plus de mois de stock : en fonction des ventes du mois d'octobre et de la quantité d'un référence, on détermine en combien de mois cette dernière va s'écouler.


On remarque que sur le 20 références qui ont la valeur la plus forte 17 sont des champagnes.

A l'approche des fêtes de fin d'année, l'entreprise a dû prévoir ses stock en avance.




Corrélations

**Stock
Vente
Prix**



Une matrice de corrélation permet de visualiser et quantifier les relations linéaires entre plusieurs variables numériques d'un jeu de données.

- Proche de 1 : corrélation positive forte -> les deux variables évoluent ensemble
- Proche de -1 : corrélation négative forte -> inversement proportionnel
- Proche de 0 : peu ou pas de relation linéaire



M E R C I



Giffaux Thomas