

LaPage

librairie



*Giffaux Thomas
Data Analyst*

Sommaire

Partie 1 : Analyse exploratoire des données

- Analyse des bases de données
- Traitement des données



Partie 2 : Analyses des données

- Evolution du Chiffre d'Affaires
- Volume d'activité
- Analyse des catégorie de livre
- Top références
- Flop références
- Profils clients



Partie 3 : Test statistique

Partie 4 : Conclusion

Partie 1

Analyse exploratoire des données



Analyse des bases de données



Customers.csv

8 621 clients

Client le plus âgé : 1929

Client le plus jeune : 2004

Genre : féminin ou masculin

client_id : clé primaire

Pas de doublon ou
d'anomalie sur le fichier



Products.csv

3 286 références produits

Prix moyen : 21,86 €

Prix min : 0,62 €

Prix max : 300 €

Catégories : 0; 1; 2

id_prod : clé primaire

Pas de doublon ou
d'anomalie sur le fichier



Transaction.csv

687 534 lignes

361 040 lignes en doublons (valeurs Nan)

Référence la plus vendus : 1_369

Client c_1609 + 25 000 livres achetés
Après vérification 3 autres clients ont plus
de 5 000 livres achetés. Client BtoB ?

Format date compliqué à exploiter, à
modifier pour mieux analyser les données.



Traitements des données




Partie 2

Analyses des données




Evolution du chiffre d'affaire

CA par mois



Évolution du CA mensuel avec moyennes mobiles



2022
6 108 681,81 €

2021
4 944 760,98 €

2023
974 220,31 €




CA total : 12 027 663,10 €

- 2022 seule année complète dans les données.
- Le CA global reste relativement stable, autour de 500 000 € par mois.
- Pas de chute brutale, ce qui indique une activité régulière.
- La meilleure année est 2022, avec plusieurs mois au-dessus des 520 000 €.
- En 2023, une baisse nette en février avec le plus bas niveau.
- Légère augmentation en novembre et décembre, ce qui peut suggérer une saisonnalité pour les fêtes de fin d'année.




Volume d'activité


Nombre de transaction par mois



Nombre de livres vendus par mois




Nombre de client par mois



- Le nombre de transactions, de livres vendus et de clients montrent une stabilité générale d'une année à l'autre.
- On observe une variabilité saisonnière, avec des pics d'activité en fin d'année.
- Décembre est un mois qui est fort sur les indicateurs (2021 : 15 566 transactions et 32 457 livres vendus; 2022 : 14 634 transactions et 28 619 livres vendus).
- L'année 2023 commence avec une baisse du nombre de client.
- Le nombre de livres vendus ne progresse pas, cela pourrait indiquer une saturation, une fidélisation stagnante.


Catégorie de livres



- La catégorie 0 est celle avec le plus grand nombre de référence mais aussi celle qui vend le plus de livre. Elle n'est pourtant que deuxième en CA, dû à un prix moyen plus bas par rapport aux autres catégories.
- La catégorie 1 vend beaucoup moins de livres que la catégorie 0 mais comme son prix moyenne est presque au double de cette dernière, c'est la catégorie qui génère le plus de chiffre d'affaires.
- La catégorie 2 est celle qui vend le moins de livres mais à le prix moyen le plus élevé.

Catégorie de livres

Evolution du CA mensuelle par catégorie




- L'évolution du CA pour chaque catégorie est stable dans le temps.
- On observe une augmentation pour la catégorie 0 en septembre 2021.
- On observe une augmentation pour la catégorie 1 sur la période septembre 2021 à janvier 2022.
- On observe une diminution pour la catégorie 2 sur la période août 2021 à janvier 2022.
- A partir de janvier 2022 plus de fluctuation du CA.




Top produits


Top 5 des références en volume de vente



Top 5 des références en CA



Top 5 références vendu à un client unique



- Dans le top 5 des livres les plus vendus, on observe qu'ils appartiennent tous à la catégorie 1.
- Dans le top 5 des livres qui ont rapporté le plus de chiffre d'affaires, on observe qu'ils appartiennent tous à la catégorie 2.

Comme vue précédemment le prix moyen d'un livre de la catégorie 2 est bien supérieur à un livre de la catégorie 1. Ce qui explique que l'on retrouve que des livres de la catégorie 2 dans le top 5 CA.

- Dans le top 5 des référence vendu à un client unique, on retrouve que des livres de la catégorie 1. Ce sont les "best sellers", les livres qui ramène le plus de client.



Flop produits



Flop 5 des références en CA



Références qui n'ont jamais été achetés :

- | | |
|----------|----------|
| - 0_1014 | - 0_2308 |
| - 0_1016 | - 0_299 |
| - 0_1025 | - 0_310 |
| - 0_1062 | - 0_322 |
| - 0_1119 | - 0_510 |
| - 0_1318 | - 1_0 |
| - 0_1620 | - 1_394 |
| - 0_1624 | - 2_72 |
| - 0_1645 | - 2_86 |
| - 0_1780 | - 2_87 |
| - 0_1800 | |

- 21 références de livre n'ont pas été achetées durant la période de mars 2021 à février 2023.
- Sur cette même période 93 références ont été achetées que 3 fois ou moins.

A voir si ces références sont pertinentes dans le catalogue de référence que propose la librairie.



Profils clients



4 118 clients (47,9 %)
5 346 441,93 € de CA (48 %)



4 478 clients (52,1 %)
5 796 925,08 € de CA (52 %)

18-30

1 944 clients (22,6 %)
2 628 841,15 € de CA (23,6 %)

30-45

2 542 clients (29,6 %)
3 933 802,33 € de CA (35,3 %)

45-60

2 344 clients (27,3 %)
2 934 566,52 € de CA (26,3 %)

60+


1 766 clients (20,5 %)
1 646 157,01 € de CA (14,8 %)

- La répartition du nombre de client et du CA en fonction du genre est plutôt équilibrée.
- Pour la répartition par l'âge, la tranche 30-45 est la plus grande en nombre et en CA. Suivi de la tranche 45-60.

La répartition des clients selon leur âge est assez équilibré, on observe néanmoins que la tranche 30-45 ans est celle qui dépense le plus.



Profils clients



Si on compare par tranche d'âge, la répartition du CA est plutôt équilibré en fonction du genre du client. Les femmes dépense un peu plus que les hommes quelque soit l'âge.





Partie 3

Test statistique

Pourquoi utiliser des tests statistiques ? Ils permettent de valider objectivement des hypothèses en répondant à une question essentielle :

Les différences ou relations observées dans les données sont-elles réellement significatives ou dues au hasard ?

Les avantages :

- **Objectivité** : basés sur des probabilités, ils évitent les conclusions biaisées.
- **Crédibilité** : renforcent la validité des constats présentés.
- **Décision** : aident à savoir si une différence ou lien est exploitable pour l'action marketing ou commerciale.




Lien entre genre du client et les catégories des livres achetés

Pour deux valeurs qualitatives (genre et catégorie), on utilise le test χ^2 d'indépendance.

Résultats :

- $\chi^2 = 22.67$
- $p\text{-value} = 0.00$



Il existe donc bien une faible dépendance entre genre du client et les catégories des livres achetés.


Lien entre l'âge du client et le montant total des achats

Ici nous avons deux variables quantitatives (âge et montant d'achat). On utilise le test de corrélation Pearson si nos variables suivent une distribution normales, sinon on utilise le test Spearman.

Après un test de normalité, les deux variables ne suivent pas une distribution normale.

Résultats :

- $C = -0.1845$
- $P_value = 1.021e-66$




Plus l'âge augmente, plus le montant d'achat tend à baisser. Mais la relation n'est pas significative.

Lien entre l'âge du client et la fréquence d'achat

Ici on utilise le test ANOVA qui permet de comparer les moyennes d'une variable quantitative (fréquence d'achat) entre plusieurs groupes définis (tranche d'âge).

Résultats :

- $F = 613.71$
- $p_value = 0.00$




Il existe une forte relation entre l'âge et la fréquence d'achat. Les tranches d'âge 30-45 et 45-60 sont les plus actives.

Lien entre l'âge du client et la taille du panier moyen

Ici on utilise le test ANOVA qui permet de comparer les moyennes d'une variable quantitative (panier moyen) entre plusieurs groupes définis (tranche d'âge).

Résultats :

- $F = 2998.80$
- $p_value = 0.00$




Il y a une très forte relation entre l'âge du client et le montant de son panier moyen. La tranche d'âge 18-30 on un panier moyen qui est deux fois supérieur aux autres.

Lien entre l'âge du client et les catégorie des livres achetés

Pour deux valeurs qualitatives (âge et catégorie), on utilise le test χ^2 d'indépendance.

Résultats :

- $\chi^2 = 216317.60$
- $p_value = 0.00$



Il existe donc une forte dépendance entre l'âge et les catégories des livres achetés. On peut observer par exemple que la catégorie 2 est plus achetée par les 18-30 ans et la catégorie 0 par les 30-45 ans.

Partie 4

Conclusion



Observations

Tendance générale des ventes :

- CA mensuel suit une tendance à la hausse entre 2021 et 2023 avec une légère baisse en février 2023.
- Des pics de ventes récurrents en fin d'année et des mois d'été plus calme.
- Les clients les plus jeunes sont ceux qui dépensent le moins.

Profil clients :

- CA légèrement plus élevé chez les femmes quelque soit la tranche d'âge.
- 30-45 sont les plus actifs, ils réalisent le plus d'achat.
- 13-30 sont les moins actifs mais on a un panier moyen le plus élevé.

Catégories des livres :

- Catégories 0 et 1 sont les plus populaires et sont celles qui génèrent le plus de CA.
- Les préférences de lecture varient fortement en fonction de l'âge.

Références des livres :


- Livres de la catégorie 1 sont les plus vendus en volume et sont ceux qui amènent le plus de clients.
- Livres de la catégorie 2 sont les moins vendus mais sont ceux qui apportent le plus de CA à l'unité (prix moyen plus élevé).



Recommandations stratégiques

Les 18-30 ont une diversité d'achat intéressante et un panier moyen élevé mais une fréquence d'achat faible : **Optimisation du site ou d'une application**

Exploitation des pics saisonniers : **Actions marketings/pubs** en novembre et décembre pour renforcer les ventes pour les fêtes. Et pendant l'été pour relancer les ventes.



Les 30-45 sont les plus actifs et qui rapporte les plus de CA : **Programme de fidélisation** avec un focus sur cette tranche d'âge et les gros acheteurs.

Vérifications des références pour avoir un catalogue plus claire : **suppression** des références non vendus et **mise en avant** des best sellers.

LaPage
librairie



Merci

