

Déectez des faux billets



Sommaire

Introduction et contexte

- Objectifs
- Cadre méthodologique

Exploration des données

- Présentation des variables
- Analyse exploratoire
- Gestion des valeurs manquantes

Modélisation des algorithmes de détection

- Validation croisée
 - Régression logistique
 - K-Nearest Neighbors (KNN)
 - Random Forest
- Approche non supervisée : K-Means

Comparaison des modèles

- Performances
- Choix du modèle




Introduction et contexte



Objectifs

La détection des faux billets est un enjeu important pour lutter contre la fraude et garantir la fiabilité des systèmes de paiement. Ce projet vise à utiliser des techniques de data science et de machine learning afin de distinguer les billets authentiques des billets contrefaits à partir de caractéristiques physiques mesurées. L'objectif est d'explorer les données, de comparer plusieurs modèles de classification et de sélectionner la méthode la plus performante et la plus interprétable, tout en proposant une mise en application concrète du modèle retenu.

Cadre méthodologique



Exploration des données



Présentation des variables

diagonal : longueur
de la diagonale du
billet (en mm)

margin_up: largeur
de la marge
supérieure du billet
(en mm)

height_left : hauteur
du billet mesurée
sur le bord gauche
(en mm)

height_right :
hauteur du billet
mesurée sur le bord
droit (en mm)



is_genuine : variable
indiquant si le billet est
authentique (True) ou
contrefait (False)

length : longueur
totale du billet (en
mm)

margin_low : largeur
de la marge inférieure
du billet (en mm)

Analyse exploratoire

	is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length
0	True	171.81	104.86	104.95	4.52	2.89	112.83
1	True	171.46	103.36	103.66	3.77	2.99	113.09
2	True	172.69	104.48	103.50	4.40	2.94	113.16
3	True	171.36	103.91	103.94	3.62	3.01	113.51
4	True	171.73	104.28	103.46	4.04	3.48	112.54



```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1500 entries, 0 to 1499
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   is_genuine   1500 non-null   bool
1   diagonal     1500 non-null   float64
2   height_left  1500 non-null   float64
3   height_right 1500 non-null   float64
4   margin_low   1463 non-null   float64
5   margin_up    1500 non-null   float64
6   length       1500 non-null   float64
dtypes: bool(1), float64(6)
memory usage: 71.9 KB
```

	diagonal	height_left	height_right	margin_low	margin_up	length
count	1500.000000	1500.000000	1500.000000	1463.000000	1500.000000	1500.000000
mean	171.958440	104.029533	103.920307	4.485967	3.151473	112.67850
std	0.305195	0.299462	0.325627	0.663813	0.231813	0.87273
min	171.040000	103.140000	102.820000	2.980000	2.270000	109.49000
25%	171.750000	103.820000	103.710000	4.015000	2.990000	112.03000
50%	171.960000	104.040000	103.920000	4.310000	3.140000	112.96000
75%	172.170000	104.230000	104.150000	4.870000	3.310000	113.34000
max	173.010000	104.880000	104.950000	6.900000	3.910000	114.44000

- 1 500 billets
- 1 variable qualitative / 6 quantitatives
- Pas de valeur aberrante

Pas de doublons dans le fichier mais **37 valeurs** manquantes dans la colonne margin_low.


Analyse exploratoire



- **length** et **margin_low** sont les variables qui ont la plus forte corrélation avec **is_genuine**
- **diagonal** est la variable qui a le moins de corrélation avec **is_genuine**

Gestion des valeurs manquantes

La régression linéaire multiple consiste à combiner plusieurs caractéristiques du billet afin d'estimer une valeur manquante. Elle a été utilisée ici pour estimer et remplacer les valeurs manquantes de `margin_low` à partir des autres caractéristiques physiques du billet.



- $R^2 = 0.617$: le modèle explique 62 % de la variance
- F-statistic = 469.1 et p-value ≈ 0 : modèle globalement significatif.

Variables explicative

- `is_genuine` : coefficient -1.14
- `margin_up` : coefficient -0.21

Modélisation des algorithmes de détection




Validation croisée

La validation croisée, est une technique d'échantillonnage qui garantit que le modèle est testé sur plusieurs ensembles de données différents, réduisant ainsi les biais liés à une seule division des données. Elle permet donc de sélectionner le modèle le plus performant de manière fiable.



Régression logistique

La régression logistique est une méthode statistique qui permet d'étudier les relations entre un ensemble de variables qualitatives (x) et une variable qualitative (y).





Variable Coefficient

- diagonal → 0.190926
- height_left → -0.408372
- height_right → -0.765401
- margin_up → -1.726202
- margin_low → -2.833396
- length → 3.713067


K-Nearest Neighbors (KNN)

L'algorithme des k plus proches voisins (KNN) est un modèle supervisé basé sur la proximité entre les observations. Pour classifier un nouvel échantillon, le modèle recherche les k observations les plus proches dans l'espace des données, puis détermine sa classe en fonction de la majorité parmi ces voisins.



Random Forest

Random Forest est un algorithme supervisé de classification basé sur le principe de l'ensemble learning. Il construit un grand nombre d'arbres de décision, chacun entraîné sur un échantillon aléatoire des données et une sélection partielle des variables.





Variable Coefficient

- diagonal → 0.008133
- height_left → 0.027766
- height_right → 0.044524
- margin_up → 0.110378
- margin_low → 0.326666
- length → 0.482534

Approche non supervisée : K-Means

K-Means est un algorithme de clustering non supervisé qui vise à regrouper des observations en k groupes distincts en minimisant la distance intra-cluster. Chaque cluster est représenté par un centroïde, calculé comme la moyenne des points qui lui sont associés.



Comparaison des modèles



Performances

Régression logistique	Vrais +	Vrais -	Faux +	Faux -
	998	492	8	2
KNN	Vrais +	Vrais -	Faux +	Faux -
	996	489	11	4
Random Forest	Vrais +	Vrais -	Faux +	Faux -
	998	490	10	2
K-Means	Vrais +	Vrais -	Faux +	Faux -
	990	486	14	10

Choix du modèle

Plusieurs méthodes de détection des faux billets ont été comparées après un traitement des données et une validation croisée stratifiée. Les modèles supervisés (régression logistique, KNN et Random Forest) obtiennent tous d'excellentes performances, avec une accuracy supérieure à 99 %.

Régression logistique → Au regard des résultats obtenus, c'est un excellent compromis entre performance, stabilité et interprétabilité, ce qui en fait le modèle le plus adapté pour une mise en production.

Les modèles KNN et Random Forest constituent de solides alternatives, tandis que le K-Means apporte un éclairage intéressant sur la structure des données, sans être adapté comme solution finale de détection

Merci

